

Sofiane TAREB

Data Scientist / AI Engineer

[Portfolio](#)

[GitHub](#)

✉ sofianetareb.pro@gmail.com

☎ +336 09 89 60 78

🏠 Rennes (35000), France

Ingénieur IA avec une expérience concrète en conception et mise en production de plateformes d'IA Générative : RAG agentique, applications métier, évaluation automatisée des modèles et observabilité. À l'aise du prototype à la mise en production, je recherche un poste où allier rigueur technique et impact business autour de l'IA Générative.

EXPÉRIENCES PROFESSIONNELLES

AI Engineer - Rennes métropole - Rennes, France

Depuis Fév. 2025

Sujet : Conception et mise en production d'une plateforme d'IA générative : RAG agentique, applications métier, évaluation automatisée des modèles et observabilité.

- Conception et déploiement en production d'un RAG agentique (Agents LLM avec orchestration d'outils et mémoire) exploitant les bases documentaires hétérogènes des différents services.
- Mise en production d'Open WebUI comme interface d'accès aux modèles et assistants, avec gestion des utilisateurs et des permissions
- Développement et sécurisation d'APIs robustes pour l'intégration de la plateforme avec les services existants.
- Implémentation de l'authentification SSO-OAuth et de la sécurisation HTTPS pour garantir la conformité et la sécurité en production.
- Conception d'une application qui automatise le traitement des documents, centralise la gestion des bases de connaissances et gère désormais les accès et les droits des utilisateurs.
- Mise en place d'un système d'évaluation automatisée du retriever et du générateur (jeux de tests, métriques de pertinence et de fidélité) pour piloter l'amélioration continue.
- Instrumentation de la plateforme avec Langfuse : traçage des chaînes LLM, suivi des performances et des coûts, observabilité en production.
- Développement et mise en production d'une application de transcription audio avec synthèse automatique par IA.
- Développement d'applications et interfaces web pour différents cas d'usages.
- Pilotage du passage du POC à la production et accompagnement des équipes métier dans l'expérimentation et la validation des prototypes.

Outils : Agentic RAG, LLM Agents, Python, FastAPI, Speech to Text, Docker, GitLab, CI/CD, Open WebUI, Langfuse, SSO-OAuth, NLP

Stage - Analyse et traitement de données - TA-Consulting - Paris, France

Déc. 2022

Sujet : Analyse et modélisation de données pour l'optimisation du déploiement d'antennes réseau SFR.

- Préparation et analyse de données techniques et géographiques liées aux infrastructures réseau.
- Développement de modèles de Machine Learning pour prédire la couverture et identifier les zones à améliorer.
- Analyse des facteurs influençant les performances des antennes.
- Création de visualisations et cartes pour faciliter le dimensionnement et la planification du réseau.

Outils : Python, R, Machine Learning, Data Visualisation

FORMATIONS ET DIPLÔMES

Master MAS parcours SDD et IA - Université Rennes 2 - Rennes, France

Sep. 2023 - Aou. 2025

Licence MIASHS - Université Clermont Auvergne - Clermont Ferrand, France

Sep. 2021 - Aou. 2023

Licence MI parcours Recherche Opérationnelle - USTHB - Alger, Algérie

Sep. 2017 - Aou. 2021

COMPÉTENCES

IA & GenAI : Agentic RAG, LLM Agents, NLP, Machine Learning, Deep Learning, Speech-to-Text.

LLM & Frameworks : LangGraph, LangChain, Hugging Face, Langfuse, Open WebUI.

Backend & APIs : Python, FastAPI, Flask, APIs REST.

Data : SQL, Big Data, Data Visualisation.

DevOps & Cloud : Git, GitHub/GitLab, CI/CD, Docker, GCP, RabbitMQ.

LANGUES

Français, Anglais, Arabe, Kabyle

ATOUTS

Autonomie, Curiosité, Analyse